Лабораторна робота № 3

Діагностика шкал вимірювання

Курс СК26 «Інтелектуальний аналіз та візуалізація даних»

Тривалість: 2 год аудиторно + 3 год самостійно · **Оцінка:** 4 бали **Файли:** `Ковід_дані_навчальні.xlsx` , `ЛР3_помилковий_аналіз.ipynb`

Шкала вимірювання визначає, які операції над змінною взагалі мають сенс. Комп'ютер цього не знає: він порахує середнє від номера телефону й не поскаржиться. Знати має вимірювач.

У цій роботі ви складаєте **паспорт восьми змінних** свого варіанта, показуєте на власних даних, які статистики для них недопустимі, і виправляєте чужий аналіз, де таких помилок десять.

In [1]:
```
ПРІЗВИЩЕ_ІМЯ = 'Бобринок Ангеліна'      # напишіть тут своє прізвище та ім'я
ГРУПА        = 'ШІ-32'
НОМЕР        = 3       # ваш номер за списком групи (1–30)

assert ПРІЗВИЩЕ_ІМЯ and ГРУПА and НОМЕР, 'Заповніть три поля вище'
assert 1 <= НОМЕР <= 30, 'Номер має бути від 1 до 30'
```

In [2]:
```
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
import warnings
warnings.filterwarnings('ignore')

pd.set_option('display.max_colwidth', None)   # повний текст у таблицях (для PDF)

ВАРІАНТИ = json.load(open('lr3_variants_student.json'))
В = ВАРІАНТИ[НОМЕР - 1]

print('=' * 74)
print(f'ВАРІАНТ {В["варіант"]}   ·   {ПРІЗВИЩЕ_ІМЯ}   ·   {ГРУПА}')
print('=' * 74)
print()
print('Ваші вісім стовпців:')
for i, c in enumerate(В['стовпці'], 1):
    print(f'   {i}. {c}')
print()
print('Ваша пара для аналізу зв’язку:', ' та '.join(В['пара']))
print()
print('Ваше додаткове питання:')
print('  ', В['питання'])
```

```
================================================================================
ВАРІАНТ 3   ·   Бобринок Ангеліна   ·   ШІ-32
================================================================================

Ваші вісім стовпців:
   1. номер і/х
   2. помер/жив
   3. Перебіг
   4. Виписка
   5. sp02 без дот
   6. Креат1
   7. Гемогл2
   8. БРзаг2

Ваша пара для аналізу зв'язку: Перебіг та ступінь КТ

Ваше додаткове питання:
   Стовпець «помер/жив» містить числа 1 і 2. Які три різні статистики
pandas порахує для нього без жодної скарги — і чому кожна з них безглузда?
```

In [3]:
```python
ФАЙЛ = 'Ковід_дані_навчальні.xlsx'
df = pd.read_excel(ФАЙЛ, sheet_name='Лист1', engine='openpyxl')
МОЇ = В['стовпці']

print('Розмір набору:', df.shape)
df[МОЇ].head(8)
```

```
Розмір набору: (121, 77)
```

Out[3]:

	номер і/х	помер/жив	Перебіг	Виписка	spO2 без дот	Креат1	Гемогл2	БРзаг2
0	2377/239	1	важкий	2022-03-10 00:00:00	90.0	84	144	17.0
1	1121/19	2	важкий	2022-03-16 00:00:00	83.0	75.4	137	13.6
2	283/674	2	важкий	2022-01-18 00:00:00	78.0	80.7	105	18.7
3	2372/513	2	важкий	2022-01-13 00:00:00	82.0	168.1	116	13.6
4	1441/671	2	важкий	2022-03-11 00:00:00	80.0	76	124	15.3
5	2573/354	1	важкий	2021-12-26 00:00:00	72.0	130	120	15.3
6	1762/555	2	важкий	2022-05-11 00:00:00	89.0	98	151	15.3
7	2664/348	2	серед важ	2022-05-28 00:00:00	90.0	118	137	15.3

Етап 1. Паспорт змінних

Для кожного з восьми стовпців визначте шкалу вимірювання. Спирайтеся не на тип даних у pandas, а на **зміст величини**: що означають її значення і які порівняння між ними мають сенс.

Нагадування:

Шкала	Ознака
Номінальна	значення можна лише порівняти на рівність
Порядкова	є природний порядок, але відстані між сусідніми рівнями невідомі
Інтервальна	різниці мають сенс, нуль умовний

Шкала	Ознака
Відношень	є природний нуль, відношення мають сенс
Абсолютна	природні і нуль, і одиниця вимірювання

Окремо позначайте **ідентифікатори** — значення, що не є величиною взагалі (номер історії хвороби, прізвище, телефон).

In [4]:
```
# Спершу подивіться, що каже pandas — і не довіряйте йому
df[МОЇ].info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 121 entries, 0 to 120
Data columns (total 8 columns):
 #   Column        Non-Null Count  Dtype  
---  ------        --------------  -----  
 0   номер і/х     121 non-null    object 
 1   помер/жив     121 non-null    int64  
 2   Перебіг       121 non-null    str    
 3   Виписка       120 non-null    object 
 4   sp02 без дот  120 non-null    float64
 5   Креат1        117 non-null    object 
 6   Гемогл2       105 non-null    object 
 7   БРзаг2        101 non-null    float64
dtypes: float64(2), int64(1), object(4), str(1)
memory usage: 9.3+ KB
```

In [5]:
```
# Далі — що є всередині насправді
for c in МОЇ:
    з = df[c].dropna()
    типи = ', '.join(f'{t.__name__}×{n}' for t, n in
з.map(type).value_counts().items())
    print(f'--- {c}')
    print(f'    непорожніх {len(з)} з {len(df)} | унікальних
{з.nunique()} | типи: {типи}')
    print(f'    приклади: {[repr(v) for v in з.unique()[:4]]}')
    print()
```

```
--- номер і/х
    непорожніх 121 з 121 | унікальних 119 | типи: int×65, str×56
    приклади: ["'2377/239'", "'1121/19'", "'283/674'", "'2372/513'"]

--- помер/жив
    непорожніх 121 з 121 | унікальних 2 | типи: int×121
    приклади: ['np.int64(1)', 'np.int64(2)']

--- Перебіг
    непорожніх 121 з 121 | унікальних 3 | типи: str×121
    приклади: ["'важкий'", "'серед важ'", "'вкрай важкий '"]

--- Виписка
    непорожніх 120 з 121 | унікальних 90 | типи: datetime×118, str×2
    приклади: ['datetime.datetime(2022, 3, 10, 0, 0)',
'datetime.datetime(2022, 3, 16, 0, 0)', 'datetime.datetime(2022, 1, 18, 0,
0)', 'datetime.datetime(2022, 1, 13, 0, 0)']

--- sp02 без дот
    непорожніх 120 з 121 | унікальних 33 | типи: float×120
    приклади: ['np.float64(90.0)', 'np.float64(83.0)', 'np.float64(78.0)',
'np.float64(82.0)']

--- Креат1
    непорожніх 117 з 121 | унікальних 73 | типи: int×104, float×11, str×2
    приклади: ['84', '75.4', '80.7', '168.1']

--- Гемогл2
    непорожніх 105 з 121 | унікальних 60 | типи: int×104, str×1
    приклади: ['144', '137', '105', '116']

--- БРзаг2
    непорожніх 101 з 121 | унікальних 21 | типи: float×101
    приклади: ['np.float64(17.0)', 'np.float64(13.6)', 'np.float64(18.7)',
'np.float64(15.3)']
```

Заповніть паспорт

Для кожного стовпця вкажіть шкалу та **обґрунтування** — одне речення про те, чому саме ця шкала. Обґрунтування оцінюється, назва шкали сама по собі — ні.

In [6]:
```
ПАСПОРТ = {
    'номер і/х':    ('ідентифікатор',
                     'Номер історії хвороби лише позначає запис: формат
змішаний (1837 і 2377/239), '
                     'сума чи різниця номерів нічого не означає, і навіть
рівність ненадійна — '
                     'номери 1837 та 2526 повторюються у двох різних
пацієнтів.'),
    'помер/жив':    ('номінальна',
                     'Це бінарна категорія результату (1 = помер, 2 =
вижив); цифри 1 і 2 — лише '
                     'мітки, їх можна замінити на «так/ні», тому значення
порівнюються тільки на рівність.'),
    'Перебіг':      ('порядкова',
                     'Рівні «серед важ» < «важкий» < «вкрай важкий» мають
природний порядок тяжкості, '
                     'але відстань між сусідніми рівнями невідома й не
```

```
обов’язково однакова.'),
    'Виписка':      ('інтервальна',
                     'Дата календаря: різниця двох дат (наприклад, ліжко-
дні) має сенс, а нуль '
                     'умовний — «удвічі пізніша дата» не означає
нічого.'),
    'spO2 без дот': ('абсолютна',
                     'Сатурація — частка гемоглобіну, насиченого киснем,
у відсотках: є природний '
                     'нуль (0 %) і природна одиниця/межа (100 %), тож
відношення й частки мають сенс.'),
    'Креат1':       ('відношень',
                     'Концентрація креатиніну в мкмоль/л: нуль означає
відсутність речовини, тому '
                     '«креатинін удвічі вищий» — змістовне твердження;
одиниця вимірювання умовна.'),
    'Гемогл2':      ('відношень',
                     'Концентрація гемоглобіну в г/л має абсолютний нуль
(немає гемоглобіну), '
                     'відношення 140/70 = 2 має фізичний зміст, але
одиницю (г/л чи г/дл) обрано умовно.'),
    'БРзаг2':       ('відношень',
                     'Загальний білірубін у мкмоль/л — концентрація з
природним нулем, допустимі '
                     'відношення («білірубін утричі вищий за норму»),
одиниця умовна.'),
}

for c in МОЇ:
    ПАСПОРТ.setdefault(c, ('', ''))

паспорт_df = pd.DataFrame(
    [(c, ПАСПОРТ[c][0], ПАСПОРТ[c][1]) for c in МОЇ],
    columns=['Стовпець', 'Шкала', 'Обґрунтування'])
паспорт_df
```

Out[6]:

	Стовпець	Шкала	Обґрунтування
0	номер і/х	ідентифікатор	Номер історії хвороби лише позначає запис: формат змішаний (1837 і 2377/239), сума чи різниця номерів нічого не означає, і навіть рівність ненадійна — номери 1837 та 2526 повторюються у двох різних пацієнтів.
1	помер/жив	номінальна	Це бінарна категорія результату (1 = помер, 2 = вижив); цифри 1 і 2 — лише мітки, їх можна замінити на «так/ні», тому значення порівнюються тільки на рівність.
2	Перебіг	порядкова	Рівні «серед важ» < «важкий» < «вкрай важкий» мають природний порядок тяжкості, але відстань між сусідніми рівнями невідома й не обов’язково однакова.
3	Виписка	інтервальна	Дата календаря: різниця двох дат (наприклад, ліжко-дні) має сенс, а нуль умовний — «удвічі пізніша дата» не означає нічого.
4	spO2 без дот	абсолютна	Сатурація — частка гемоглобіну, насиченого киснем, у відсотках: є природний нуль (0 %) і природна одиниця/межа (100 %), тож відношення й частки мають сенс.
5	Креат1	відношень	Концентрація креатиніну в мкмоль/л: нуль означає відсутність речовини, тому «креатинін удвічі вищий» — змістовне твердження; одиниця вимірювання умовна.
6	Гемогл2	відношень	Концентрація гемоглобіну в г/л має абсолютний нуль (немає гемоглобіну), відношення 140/70 = 2 має фізичний зміст, але одиницю (г/л чи г/дл) обрано умовно.
7	БРзаг2	відношень	Загальний білірубін у мкмоль/л — концентрація з природним нулем, допустимі відношення («білірубін утричі вищий за норму»), одиниця умовна.

In [7]:
```
# --- САМОПЕРЕВІРКА 1 ---
ДОПУСТИМІ = {'номінальна', 'порядкова', 'інтервальна', 'відношень',
             'абсолютна', 'ідентифікатор'}
for с in МОЇ:
    ш, об = ПАСПОРТ[с]
    assert ш.strip().lower() in ДОПУСТИМІ, f'{с}: шкалу «{ш}» не
розпізнано'
    assert len(об.strip()) >= 25, f'{с}: обґрунтування закоротке'
print('Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та
обґрунтування.')
```

```
Самоперевірка 1 пройдена: усі вісім стовпців мають шкалу та обґрунтування.
```

Етап 2. Допустимі статистики

Для кожного стовпця обчисліть **тільки те, що дозволяє його шкала**.

- номінальна та ідентифікатор — мода, частоти
- порядкова — додатково медіана та квантилі
- інтервальна — додатково середнє та стандартне відхилення
- відношень і абсолютна — усе, зокрема коефіцієнт варіації

Якщо для стовпця не можна порахувати нічого, крім частот, — так і напишіть.

Підготовка значень до обчислень

Перш ніж рахувати, треба привести значення до того типу, якого вимагає шкала. У моїх стовпцях є дефекти введення:

- `Креат1` — рядки `'109.9'` (число, записане текстом) і `'даних'` (слово замість пропуску);
- `Гемогл2` — рядок `'немає'`;
- `Виписка` — дві неіснуючі дати `'24.024.2021'` і `'20.24.2021'`;
- `sp02 без дот` — значення `0.9`: сатурацію записано часткою, а не відсотками (90 %);
- `Перебіг` — `'вкрай важкий '` із пробілом у кінці.

In [8]:
```
ПОРЯДОК_ПЕРЕБІГ = ['серед важ', 'важкий', 'вкрай важкий']   # порядок
задано вручну


def очищений(стовпець):
    """Повертає стовпець, приведений до типу, якого вимагає його
шкала."""
    s = df[стовпець]
    if стовпець == 'Перебіг':
        return pd.Categorical(s.str.strip(), categories=ПОРЯДОК_ПЕРЕБІГ,
ordered=True)
    if стовпець == 'Виписка':
        return pd.to_datetime(s, errors='coerce')          #
'24.024.2021' -> NaT
```

```
    if стовпець == 'spO2 без дот':
        s = pd.to_numeric(s, errors='coerce')
        return s.where(s > 1, s * 100)                    # 0.9 -> 90 %
    if ПАСПОРТ[стовпець][0] in ('відношень', 'абсолютна'):
        return pd.to_numeric(s, errors='coerce')          # 'даних',
'немає' -> NaN
    return s


for c in ['Креат1', 'Гемогл2', 'Виписка', 'spO2 без дот']:
    сире = df[c].notna().sum()
    чисте = pd.Series(очищений(c)).notna().sum()
    print(f'{c:14s} непорожніх до очищення: {сире:3d}, після:
{чисте:3d}')
```

```
Креат1         непорожніх до очищення: 117, після: 116
Гемогл2        непорожніх до очищення: 105, після: 104
Виписка        непорожніх до очищення: 120, після: 118
spO2 без дот   непорожніх до очищення: 120, після: 120
```

In [9]:

```
def допустима_статистика(стовпець, шкала):
    """Повертає словник статистик, дозволених для цієї шкали."""
    з = pd.Series(очищений(стовпець)).dropna()
    р = {'непорожніх': len(з), 'унікальних': з.nunique()}
    ш = шкала.strip().lower()

    if ш in ('ідентифікатор',):
        return р

    # усі шкали: мода й частоти
    частоти = з.value_counts()
    р['мода'] = частоти.index[0]
    р['частоти (топ-3)'] = частоти.head(3).to_dict()

    if ш == 'номінальна':
        return р

    # порядкова і вище: медіана та квартилі
    if ш == 'порядкова':
        коди = з.cat.codes                                # коди за заданим
порядком
        р['медіана'] = з.cat.categories[int(коди.median())]
        р['Q1'] = з.cat.categories[int(коди.quantile(.25,
interpolation='lower'))]
        р['Q3'] = з.cat.categories[int(коди.quantile(.75,
interpolation='higher'))]
        return р

    р['медіана'] = з.median()
    р['Q1'], р['Q3'] = з.quantile(.25), з.quantile(.75)

    # інтервальна і вище: середнє, стандартне відхилення, різниці
    р['середнє'] = з.mean()
    р['стд. відхилення'] = з.std()
    р['розмах (max − min)'] = з.max() − з.min()
    if ш == 'інтервальна':
        return р

    # відношень і абсолютна: коефіцієнт варіації, геометричне середнє
    р['коеф. варіації, %'] = 100 * з.std() / з.mean()
    р['геом. середнє'] = stats.gmean(з[з > 0])
```

```
    p['max / min'] = з.max() / з.min()
    return p


for с in МОЇ:
    print(f'--- {с}  ({ПАСПОРТ[с][0]})')
    for k, v in допустима_статистика(с, ПАСПОРТ[с][0]).items():
        if isinstance(v, float):
            v = round(v, 2)
        print(f'    {k:20s}: {v}')
    print()
```

```
--- номер і/х  (ідентифікатор)
    непорожніх          : 121
    унікальних          : 119

--- помер/жив  (номінальна)
    непорожніх          : 121
    унікальних          : 2
    мода                : 1
    частоти (топ-3)     : {1: 61, 2: 60}

--- Перебіг  (порядкова)
    непорожніх          : 121
    унікальних          : 3
    мода                : важкий
    частоти (топ-3)     : {'важкий': 90, 'серед важ': 30, 'вкрай важкий':
1}
    медіана             : важкий
    Q1                  : важкий
    Q3                  : важкий

--- Виписка  (інтервальна)
    непорожніх          : 118
    унікальних          : 88
    мода                : 2021-11-19 00:00:00
    частоти (топ-3)     : {Timestamp('2021-11-19 00:00:00'): 3,
Timestamp('2021-09-07 00:00:00'): 3, Timestamp('2021-09-15 00:00:00'): 3}
    медіана             : 2022-03-15 00:00:00
    Q1                  : 2021-11-16 18:00:00
    Q3                  : 2022-04-27 18:00:00
    середнє             : 2022-01-29 18:06:06.101695
    стд. відхилення     : 109 days 12:34:32.263270
    розмах (max - min)  : 421 days 00:00:00

--- spO2 без дот  (абсолютна)
    непорожніх          : 120
    унікальних          : 32
    мода                : 80.0
    частоти (топ-3)     : {80.0: 12, 90.0: 11, 86.0: 10}
    медіана             : 84.0
    Q1                  : 79.75
    Q3                  : 89.25
    середнє             : 82.79
    стд. відхилення     : 9.68
    розмах (max - min)  : 48.0
    коеф. варіації, %   : 11.69
    геом. середнє       : 82.16
    max / min           : 1.96

--- Креат1  (відношень)
    непорожніх          : 116
    унікальних          : 72
    мода                : 76.0
    частоти (топ-3)     : {76.0: 5, 129.0: 4, 95.0: 4}
    медіана             : 101.0
    Q1                  : 82.75
    Q3                  : 126.0
    середнє             : 108.14
    стд. відхилення     : 35.31
    розмах (max - min)  : 223.7
    коеф. варіації, %   : 32.65
```

```
    геом. середнє       : 103.43
    max / min           : 4.86

--- Гемогл2  (відношень)
    непорожніх          : 104
    унікальних          : 59
    мода                : 144.0
    частоти (топ-3)     : {144.0: 5, 142.0: 5, 137.0: 4}
    медіана             : 134.0
    Q1                  : 116.0
    Q3                  : 144.0
    середнє             : 128.71
    стд. відхилення     : 23.51
    розмах (max - min)  : 139.0
    коеф. варіації, %   : 18.27
    геом. середнє       : 126.19
    max / min           : 3.73

--- БРзаг2  (відношень)
    непорожніх          : 101
    унікальних          : 21
    мода                : 15.3
    частоти (топ-3)     : {15.3: 26, 13.6: 19, 18.7: 17}
    медіана             : 15.3
    Q1                  : 13.6
    Q3                  : 18.7
    середнє             : 16.22
    стд. відхилення     : 5.54
    розмах (max - min)  : 53.1
    коеф. варіації, %   : 34.14
    геом. середнє       : 15.65
    max / min           : 8.18
```

Що недопустимо для кожного стовпця:

- `номер і/х` — нічого, крім кількості та унікальності; навіть мода (1837) показує не «типовий номер», а помилку введення — два різних пацієнти з одним номером;
- `помер/жив` — лише частоти та мода; медіана, середнє й стд. відхилення залежать від того, якими цифрами закодовано категорії;
- `Перебіг` — медіана і квартилі за **заданим** порядком; середнє недопустиме, бо відстані між «серед важ», «важкий» і «вкрай важкий» невідомі;
- `Виписка` — середнє, стд. і різниці дат; коефіцієнт варіації чи «max / min» недопустимі, бо нуль дати (1970-01-01 у pandas) умовний;
- `sp02 без дот`, `Креат1`, `Гемогл2`, `БРзаг2` — усі статистики, включно з CV і геометричним середнім.

Етап 3. Три безглузді числа

`df.describe()` порахує статистики для всього, що схоже на число. Частина цих чисел не має жодного змісту.

Знайдіть **щонайменше три** такі числа у своєму наборі: обчисліть їх, а потім поясніть, чому кожне з них безглузде.

In [10]:
```
df[МОЇ].describe(include='all').T
```

Out[10]:

	count	unique	top	freq	mean	std	min	25%	50%	75%	max
номер і/х	121.0	119.0	1837.0	2.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
помер/жив	121.0	NaN	NaN	NaN	1.495868	0.502062	1.0	1.0	1.0	2.0	2.0
Перебіг	121	3	важкий	90	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Виписка	120	90	2021-11-19 00:00:00	3	NaN	NaN	NaN	NaN	NaN	NaN	NaN
spO2 без дот	120.0	NaN	NaN	NaN	82.049167	12.208249	0.9	78.75	84.0	89.0	98.0
Креат1	117.0	73.0	76.0	5.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
Гемогл2	105.0	60.0	144.0	5.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN
БРзаг2	101.0	NaN	NaN	NaN	16.216832	5.537094	7.4	13.6	15.3	18.7	60.5

In [11]:
```
номер_як_число = pd.to_numeric(df['номер і/х'], errors='coerce')
пж = df['помер/жив']

БЕЗГЛУЗДІ = [
    ('помер/жив', 'mean', round(пж.mean(), 3),
     'Середнє номінальних міток: «1.496» не є жодним результатом
лікування; якщо закодувати '
     'помер=0, вижив=1, вийде 0.496, а при 1/0 — 0.504, тобто число
залежить від довільного кодування.'),
    ('помер/жив', 'std', round(пж.std(), 3),
     'Стандартне відхилення відстаней між мітками 1 і 2 — відстаней між
«помер» і «вижив» '
     'не існує, тому і розкиду навколо «середнього результату» немає.'),
    ('помер/жив', '50% (медіана)', пж.median(),
     'Медіана вимагає порядку; «медіанний пацієнт помер» — артефакт того,
що смерть закодовано '
     'меншою цифрою (61 проти 60). Поміняйте коди — і медіана «оживе».'),
    ('spO2 без дот', 'min', df['spO2 без дот'].min(),
     'Сатурація 0.9 % несумісна з життям — це 90 %, записані часткою.
Число арифметично правильне, '
     'але дані непридатні: воно також тягне вниз середнє (82.05 замість
82.79) і роздуває std.'),
    ('номер і/х', 'mean (числових номерів)', round(номер_як_число.mean(),
1),
     'Середнє ідентифікаторів — це «середній номер історії хвороби», який
не належить жодному '
     'пацієнту й нічого не вимірює; до того ж половину номерів (формат
«2377/239») відкинуто.'),
    ('номер і/х', 'top (мода)', df['номер і/х'].mode()[0],
     'describe() показує «найчастіший номер», але ідентифікатор має бути
унікальним; '
     'freq = 2 вказує не на типове значення, а на дублікат/помилку
введення.'),
]

assert len(БЕЗГЛУЗДІ) >= 3, 'Потрібно щонайменше три приклади'
pd.DataFrame(БЕЗГЛУЗДІ, columns=['Стовпець', 'Статистика', 'Значення',
'Чому безглузде'])
```

Out[11]:

	Стовпець	Статистика	Значення	Чому безглузде
0	помер/жив	mean	1.496	Середнє номінальних міток: «1.496» не є жодним результатом лікування; якщо закодувати помер=0, вижив=1, вийде 0.496, а при 1/0 — 0.504, тобто число залежить від довільного кодування.
1	помер/жив	std	0.502	Стандартне відхилення відстаней між мітками 1 і 2 — відстаней між «помер» і «вижив» не існує, тому і розкиду навколо «середнього результату» немає.
2	помер/жив	50% (медіана)	1.000	Медіана вимагає порядку; «медіанний пацієнт помер» — артефакт того, що смерть закодовано меншою цифрою (61 проти 60). Поміняйте коди — і медіана «оживе».
3	spO2 без дот	min	0.900	Сатурація 0.9 % несумісна з життям — це 90 %, записані часткою. Число арифметично правильне, але дані непридатні: воно також тягне вниз середнє (82.05 замість 82.79) і роздуває std.
4	номер і/х	mean (числових номерів)	1770.100	Середнє ідентифікаторів — це «середній номер історії хвороби», який не належить жодному пацієнту й нічого не вимірює; до того ж половину номерів (формат «2377/239») відкинуто.
5	номер і/х	top (мода)	1837.000	describe() показує «найчастіший номер», але ідентифікатор має бути унікальним; freq = 2 вказує не на типове значення, а на дублікат/помилку введення.

Етап 4. Міра зв'язку для вашої пари

Для двох змінних вашого варіанта треба оцінити зв'язок. Міру обирає **пара шкал**, а не зручність:

Поєднання шкал	Міра
відношень × відношень	кореляція Пірсона
порядкова × порядкова	рангова кореляція Спірмена
номінальна × номінальна	χ^2 та коефіцієнт Крамера (V)
відношень × бінарна номінальна	точковий бісеріальний коефіцієнт
номінальна × порядкова	коефіцієнт Крамера (V)

Обґрунтуйте вибір, обчисліть міру й поясніть результат. Окремо покажіть, **що станеться**, якщо застосувати Пірсона там, де він недопустимий, — і чому отримане число не можна інтерпретувати.

In [12]:
```
A, B = B['пара']
print('Ваша пара:', A, '×', B)
print()
print(f'{A}: шкала —', ПАСПОРТ.get(A, ('не у вашому списку',))[0] or
'(визначте самостійно)')
print(f'{B}: шкала — порядкова (визначено самостійно: легкий < середній <
важкий < вкрай важкий < критичний)')
print()
print(df[[A, B]].head(6).to_string())
```

```
Ваша пара: Перебіг × ступінь КТ

Перебіг: шкала — порядкова
ступінь КТ: шкала — порядкова (визначено самостійно: легкий < середній <
важкий < вкрай важкий < критичний)

  Перебіг ступінь КТ
0  важкий    сердній
1  важкий   середній
2  важкий  критичний
3  важкий  критичний
4  важкий        NaN
5  важкий   середній
```

In [13]:
```
# Обидва стовпці — порядкові, але записані «як вийде». Нормалізую
написання
# і задаю порядок ВРУЧНУ: алфавітне сортування ставить «важкий» перед
«легкий».
print('ступінь КТ до очищення:',
sorted(df[B].dropna().map(repr).unique()))

ПОРЯДОК_КТ = ['легкий', 'середній', 'важкий', 'вкрай важкий',
'критичний']
СИНОНІМИ_КТ = {'легка': 'легкий', 'сердній': 'середній',
               'серед ступ': 'середній', 'серед ступеня': 'середній'}

кт_текст =
df[B].astype('string').str.strip().str.lower().replace(СИНОНІМИ_КТ)
кт = pd.Series(pd.Categorical(кт_текст, categories=ПОРЯДОК_КТ,
ordered=True), index=df.index)
перебіг = pd.Series(очищений(A), index=df.index)

пара = pd.DataFrame({A: перебіг, B: кт}).dropna()
print('ступінь КТ після очищення:', list(кт.value_counts().items()))
print(f'Пар без пропусків: {len(пара)} з {len(df)} (ступінь КТ заповнено
лише у {кт.notna().sum()} пацієнтів)')
print()
pd.crosstab(пара[A], пара[B])
```

```
ступінь КТ до очищення: ["'важкий '", "'важкий'", "'вкрай важкий '",
"'вкрай важкий'", "'критичний'", "'легка'", "'легкий '", "'легкий'",
"'сердній'", "'серед ступ'", "'серед ступеня'", "'середній'"]
ступінь КТ після очищення: [('середній', 18), ('важкий', 10), ('легкий',
7), ('вкрай важкий', 4), ('критичний', 3)]
Пар без пропусків: 42 з 121 (ступінь КТ заповнено лише у 42 пацієнтів)
```

Out[13]:

ступінь КТ	легкий	середній	важкий	вкрай важкий	критичний
Перебіг					
серед важ	6	10	1	0	0
важкий	1	8	9	3	3
вкрай важкий	0	0	0	1	0

In [14]:
```
ОБРАНА_МІРА = 'рангова кореляція Спірмена'
ЧОМУ_САМЕ_ВОНА = ('Обидві змінні порядкові (порядкова × порядкова): є
природний порядок тяжкості, '
                  'але відстані між рівнями невідомі. Спірмен
використовує лише ранги, тому не '
                  'залежить від того, якими числами закодовано рівні;
Пірсон вимагає інтервалів, '
```

```
                    'а χ²/Крамер викинули б інформацію про порядок.')

assert ОБРАНА_МІРА and len(ЧОМУ_САМЕ_ВОНА) >= 40, 'Заповніть обидва поля'

ρ, p = stats.spearmanr(пара[A].cat.codes, пара[B].cat.codes)
τ, p_τ = stats.kendalltau(пара[A].cat.codes, пара[B].cat.codes)   # контроль: багато зв'язаних рангів
print(f'Спірмен  ρ = {ρ:.3f}   p = {p:.2g}   (n = {len(пара)})')
print(f'Кендалл τ_b = {τ:.3f}   p = {p_τ:.2g}   — перевірка, бо рівнів мало й багато однакових рангів')
print()
print('Висновок: помірно-сильний додатний монотонний зв’язок — що важчий клінічний перебіг,')
print('то вищий ступінь ураження легень за КТ. Зв’язок статистично значущий (p < 0.001),')
print(f'але оцінено лише на {len(пара)} пацієнтах, у яких записано ступінь КТ, а рівень')
print('«вкрай важкий» перебіг представлено одним пацієнтом.')
```

```
Спірмен  ρ = 0.630   p = 7.8e-06   (n = 42)
Кендалл τ_b = 0.576   p = 4.7e-05   — перевірка, бо рівнів мало й багато однакових рангів

Висновок: помірно-сильний додатний монотонний зв’язок — що важчий клінічний перебіг,
то вищий ступінь ураження легень за КТ. Зв’язок статистично значущий (p < 0.001),
але оцінено лише на 42 пацієнтах, у яких записано ступінь КТ, а рівень «вкрай важкий» перебіг представлено одним пацієнтом.
```

In [15]:

```
# Контрприклад: Пірсон, застосований «як pandas дозволяє»
# (1) коди категорій за алфавітом — саме так їх видасть .astype('category')
алф_A = df[A].astype('category').cat.codes
алф_B = df[B].astype('category').cat.codes.replace(-1, np.nan)
наївна = pd.concat([алф_A, алф_B], axis=1).dropna()
r_алф = stats.pearsonr(наївна[0], наївна[1])[0]
print('Алфавітний порядок Перебіг:',
list(df[A].astype('category').cat.categories))
print(f'(1) Пірсон на алфавітних кодах сирих даних      r = {r_алф:.3f}')

# (2) правильний порядок, але коди 1,2,3,4,5 — рівні відстані, яких ніхто не міряв
r_рівні = stats.pearsonr(пара[A].cat.codes, пара[B].cat.codes)[0]
print(f'(2) Пірсон на кодах 1..5 (рівні кроки)          r = {r_рівні:.3f}')

# (3) той самий порядок, інші відстані: «вкрай важкий» = 10, «критичний» = 20
розтяг = {'легкий': 1, 'середній': 2, 'важкий': 3, 'вкрай важкий': 10, 'критичний': 20}
кт_розтяг = пара[B].astype(str).map(розтяг)
r_розтяг = stats.pearsonr(пара[A].cat.codes, кт_розтяг)[0]
ρ_розтяг = stats.spearmanr(пара[A].cat.codes, кт_розтяг)[0]
print(f'(3) Пірсон на кодах 1,2,3,10,20                 r = {r_розтяг:.3f}')
print()
print(f'Спірмен для (2) і (3): {ρ:.3f} і {ρ_розтяг:.3f} — не змінився.')
print()
print('Чому число Пірсона не можна інтерпретувати: для тих самих пацієнтів і того самого')
```

```
print('порядку воно коливається від', round(min(r_алф, r_рівні,
r_розтяг), 2), 'до',
      round(max(r_алф, r_рівні, r_розтяг), 2), '— залежно лише від
довільно обраних кодів.')
print('Алфавітні коди ще й ламають порядок («вкрай важкий» опиняється між
«важкий» і')
print('«серед важ»; «важкий »/«важкий» та 4 написання «середнього» стають
різними рівнями).')
print('Пірсон вимірює ЛІНІЙНИЙ зв’язок чисел, а відстаней між рівнями
тяжкості не існує.')
```

```
Алфавітний порядок Перебіг: ['важкий', 'вкрай важкий ', 'серед важ']
(1) Пірсон на алфавітних кодах сирих даних      r = 0.424
(2) Пірсон на кодах 1..5 (рівні кроки)          r = 0.596
(3) Пірсон на кодах 1,2,3,10,20                 r = 0.418

Спірмен для (2) і (3): 0.630 і 0.630 — не змінився.

Чому число Пірсона не можна інтерпретувати: для тих самих пацієнтів і того
самого
порядку воно коливається від 0.42 до 0.6 — залежно лише від довільно
обраних кодів.
Алфавітні коди ще й ламають порядок («вкрай важкий» опиняється між
«важкий» і
«серед важ»; «важкий »/«важкий» та 4 написання «середнього» стають різними
рівнями).
Пірсон вимірює ЛІНІЙНИЙ зв’язок чисел, а відстаней між рівнями тяжкості не
існує.
```

Етап 5. Підготовка змінних до моделі

Шкала визначає не лише статистику, а й спосіб кодування.

Шкала	Як готують до моделі
Номінальна	one-hot кодування; порядок категорій не вводять
Порядкова	впорядкована категорія або цілі коди із **заданим** порядком
Інтервальна	стандартизація; для дат — перехід до тривалостей
Відношень	нормалізація або стандартизація; можливе логарифмування
Ідентифікатор	у модель не беруть узагалі

Для кожного свого стовпця вкажіть спосіб підготовки — і **виконайте його** щонайменше для трьох стовпців різних шкал.

In [16]:
```
ПІДГОТОВКА = {
    'номер і/х':    'не беремо в модель — ідентифікатор, не величина;
лише для пошуку дублікатів',
    'помер/жив':    'one-hot / один індикатор «помер» = 1, «вижив» = 0
(бінарна номінальна, це зазвичай ціль)',
    'Перебіг':      'впорядкована категорія з кодами 0/1/2 за порядком,
заданим вручну: серед важ < важкий < вкрай важкий',
    'Виписка':      'дату саму не подаємо; переходимо до тривалості
(Виписка – Поступлення, днів) і стандартизуємо',
```

```
    'spO2 без дот': 'виправити 0.9 → 90, далі стандартизація (z-score);
можлива нормалізація min-max у [0, 1]',
    'Креат1':       'перетворити рядки на числа, логарифмувати
(правобічна асиметрія, max 281.7) і стандартизувати',
    'Гемогл2':      'перетворити «немає» на NaN, заповнити медіаною або
позначити пропуск, стандартизувати',
    'БРзаг2':       'логарифмування (викид 60.5) і стандартизація;
пропуски (20) — окремий індикатор',
}
for c in МОЇ:
    ПІДГОТОВКА.setdefault(c, '')

pd.DataFrame([(c, ПАСПОРТ[c][0], ПІДГОТОВКА[c]) for c in МОЇ],
             columns=['Стовпець', 'Шкала', 'Як готуємо'])
```

Out[16]:

	Стовпець	Шкала	Як готуємо
0	номер і/х	ідентифікатор	не беремо в модель — ідентифікатор, не величина; лише для пошуку дублікатів
1	помер/жив	номінальна	one-hot / один індикатор «помер» = 1, «вижив» = 0 (бінарна номінальна, це зазвичай ціль)
2	Перебіг	порядкова	впорядкована категорія з кодами 0/1/2 за порядком, заданим вручну: серед важ < важкий < вкрай важкий
3	Виписка	інтервальна	дату саму не подаємо; переходимо до тривалості (Виписка – Поступлення, днів) і стандартизуємо
4	spO2 без дот	абсолютна	виправити 0.9 → 90, далі стандартизація (z-score); можлива нормалізація min-max у [0, 1]
5	Креат1	відношень	перетворити рядки на числа, логарифмувати (правобічна асиметрія, max 281.7) і стандартизувати
6	Гемогл2	відношень	перетворити «немає» на NaN, заповнити медіаною або позначити пропуск, стандартизувати
7	БРзаг2	відношень	логарифмування (викид 60.5) і стандартизація; пропуски (20) — окремий індикатор

In [17]:

```
def нормалізувати(s):
    """Min-max у [0, 1] з перевіркою варіативності замість мовчазного
NaN."""
    s = pd.to_numeric(s, errors='coerce')
    розмах = s.max() - s.min()
    if not розмах > 0:
        raise ValueError(f'{s.name}: сталий стовпець (max = min),
нормалізувати неможливо')
    return (s - s.min()) / розмах


def стандартизувати(s):
    s = pd.to_numeric(s, errors='coerce')
    if not s.std() > 0:
        raise ValueError(f'{s.name}: нульове стандартне відхилення')
    return (s - s.mean()) / s.std()


підготовлені = pd.DataFrame(index=df.index)

# 1) номінальна: помер/жив -> індикатор (one-hot без зайвого стовпця для
бінарної ознаки)
підготовлені['помер'] = (df['помер/жив'] == 1).astype(int)

# 2) порядкова: Перебіг -> цілі коди за ЗАДАНИМ порядком (не алфавітним)
підготовлені['перебіг_код'] = pd.Series(очищений('Перебіг'),
index=df.index).cat.codes
```

```
# 3) інтервальна: Виписка -> тривалість перебування, потім стандартизація
днів = (очищений('Виписка') - df['Поступлення']).dt.days
днів = днів.where(днів >= 0)            # 2 записи з випискою раніше за
поступлення — помилки дат
підготовлені['тривалість_z'] = стандартизувати(днів.rename('тривалість'))

# 4) відношень: Креат1 -> log, потім min-max
підготовлені['креат1_log_norm'] =
нормалізувати(np.log(очищений('Креат1')).rename('Креат1'))

# 5) абсолютна: spO2 -> min-max
підготовлені['spO2_norm'] = нормалізувати(очищений('spO2 без
дот').rename('spO2'))

print('Перебіг -> код:', dict(zip(ПОРЯДОК_ПЕРЕБІГ, range(3))))
print(f'Від'ємна тривалість (помилки дат) відкинуто: {((
очищений("Виписка") - df["Поступлення"]).dt.days < 0).sum()}')
print()
print(підготовлені.describe().round(3).to_string())
print()
# Що буде зі сталим стовпцем (ФЕРИТ2 має одне значення з 121):
try:
    нормалізувати(df['ФЕРИТ2'])
except ValueError as e:
    print('Перевірка на сталому стовпці спрацювала:', e)
```

```
Перебіг -> код: {'серед важ': 0, 'важкий': 1, 'вкрай важкий': 2}
Від'ємна тривалість (помилки дат) відкинуто: 2

         номер  перебіг_код  тривалість_z  креат1_log_norm  spO2_norm
count  121.000      121.000       116.000          116.000    120.000
mean     0.504        0.760        -0.000            0.366      0.683
std      0.502        0.448         1.000            0.184      0.202
min      0.000        0.000        -0.844            0.000      0.000
25%      0.000        1.000        -0.462            0.225      0.620
50%      1.000        1.000        -0.174            0.351      0.708
75%      1.000        1.000         0.125            0.491      0.818
max      1.000        2.000         8.343            1.000      1.000

Перевірка на сталому стовпці спрацювала: ФЕРИТ2: сталий стовпець (max =
min), нормалізувати неможливо
```

Перед нормалізацією обов'язково перевірте варіативність. Стовпець, у якому всі значення однакові, дасть нуль у знаменнику — і мовчазний `NaN` замість помилки.

In [18]:
```
for c in МОЇ:
    з = pd.to_numeric(df[c], errors='coerce').dropna()
    if len(з) and з.nunique() == 1:
        print(f'УВАГА: {c} — сталий стовпець, нормалізація дасть ділення
на нуль')
    elif len(з) and з.max() == з.min():
        print(f'УВАГА: {c} — max дорівнює min')
print('Перевірку варіативності виконано.')
```

```
Перевірку варіативності виконано.
```

In [19]:
```
# --- САМОПЕРЕВІРКА 2 ---
assert all(len(ПІДГОТОВКА[c].strip()) >= 15 for c in МОЇ), \
```

```
    'Для кожного стовпця вкажіть спосіб підготовки'
assert len(БЕЗГЛУЗДІ) >= 3, 'Етап 3 не завершено'
print('Самоперевірка 2 пройдена.')
```

```
Самоперевірка 2 пройдена.
```

Етап 6. Виправлення чужого аналізу

Відкрийте файл **`ЛР3_помилковий_аналіз.ipynb`**. Це звіт, який виконується без жодної помилки й містить десять хибних місць.

Для кожного з десяти заповніть рядок нижче:

- **розділ** — номер розділу звіту;
- **що не так** — яка шкала порушена або яке припущення хибне;
- **чому число неправильне** — що саме воно означає насправді;
- **як правильно** — коректний варіант або обґрунтована відмова від показника.

In [20]:
```
ВИПРАВЛЕННЯ = [
    (1, 'Середнє обчислено для номінальної шкали (номер/жив); 1 і 2 — мітки, а не величини.',
        '1.50 не означає «посередині між смертю й одужанням»: такого стану не існує. При кодуванні 0/1 '
        'вийшло б 0.50, при 1/0 — 0.50 у протилежному сенсі; число залежить лише від вибору кодів.',
        'Мода й частоти: номер 61 (50.4 %), вижив 60 (49.6 %) — летальність 50.4 %.'),
    (2, 'Дані непридатні: одна номінальна категорія записана чотирма написаннями (ж/жін, ч/чол).',
        'nunique = 4 рахує варіанти написання, а не статі; «4 статі» та «найбільша група ж (46 %)» — '
        'артефакт введення, реальна частка жінок інша.',
        'Нормалізувати написання (перша літера після strip) і рахувати частоти: ж 75 (62 %), ч 46 (38 %).'),
    (3, 'Порядкова шкала: порядок узято алфавітний, написання не уніфіковано, а потім пораховано середнє кодів.',
        'Алфавіт ставить «важкий» найлегшим, а «середній» найважчим; 12 «рівнів» замість 5; середнє 5.9 '
        'кодів без відстаней — порядкова шкала середнього не допускає, тому «середній ступінь — легкий» хибне.',
        'Уніфікувати написання, задати порядок вручну (легкий<середній<важкий<вкрай важкий<критичний) і '
        'рахувати медіану/моду: медіана — «середній» (n = 42).'),
    (4, 'Дані непридатні: to_numeric(errors=coerce) мовчки викинув 17 текстових записів — 16 діапазонів («70–80%», «до 17%») і рядок із пробілів.',
        '39.6 % пораховано лише на 27 із 43 реально заповнених КТ; відкинуті діапазони здебільшого великі (60–80 %), '
        'тож середнє зміщене донизу, і це не «середній обсяг ураження» відділення.',
        'Розібрати діапазони (середина інтервалу, «до 17%» → верхня межа), привести до однієї одиниці, '
        'вказати n; для асиметричних даних — медіана з IQR.'),
    (5, 'Дані непридатні: значення 0.9 — сатурація, записана часткою (90 %), а не 0.9 %.',
```

```
        'Мінімум 0.9 фізіологічно неможливий, середнє 82.05 занижене через одну помилку; крім того, середнє '
        'не каже нічого про «більшість» пацієнтів.',
        'Виправити 0.9 → 90 (або відкинути), повідомляти медіану 84 % з IQR (79.75–89.25 %) і частку spO2 < 90 %.'),
    (6, 'Інтервальна шкала: коефіцієнт варіації (std/mean) обчислено для дат, у яких нуль умовний (1970-01-01).',
        '0.595 % — це розкид дат відносно відстані від 1970 року; перенісши нуль на 2021-01-01, отримаємо '
        'зовсім інше число. Однорідності потоку госпіталізацій воно не вимірює.',
        'Відмовитися від CV; описати розкид у днях (std ≈ 113 днів, розмах), або CV інтервалів між поступленнями.'),
    (7, 'Номінальна × номінальна: Пірсон на кодах статі та смерті; висновок «близько нуля» хибний.',
        'r = 0.177 — це φ для таблиці 2×2, а не «відсутність лінійного зв’язку»: лінійності для категорій '
        'не існує, і 0.177 — не нуль; значущість не перевірено.',
        'Таблиця спряженості, $\chi^2$ і коефіцієнт Крамера: $\chi^2 = 3.78$, $p \approx 0.052$, $V = 0.18$ — слабкий зв’язок на межі значущості.'),
    (8, 'Min-max застосовано до всіх числових стовпців, включно з номінальним помер/жив і майже порожнім/сталим ФЕРИТ2.',
        'ФЕРИТ2 має одне значення: max − min = 0, тож замість [0, 1] отримано мовчазні NaN; «усі ознаки '
        'нормалізовано» — неправда, а нормалізована мітка помер/жив не є величиною.',
        'Перед нормалізацією перевіряти розмах > 0, виключати сталі й ідентифікаційні/номінальні стовпці, '
        'номінальні кодувати one-hot.'),
    (9, 'Дані непридатні для dropna(): кожен рядок має пропуск хоча б в одному з 77 стовпців (ФЕРИТ2 — 120 NaN).',
        'Залишилось 0 рядків із 121, а висновок стверджує «повністю заповнений набір, придатний для моделі» — '
        'насправді даних для моделі немає взагалі.',
        'Видаляти пропуски лише в потрібних для аналізу стовпцях (dropna(subset=...)), відкинути стовпці з >50 % NaN, '
        'решту імпутувати.'),
    (10, 'Витік цільової змінної + інтервальна шкала: дата розтину існує лише для померлих, NaT стає числом $-9.2 \cdot 10^{18}$.',
        'r = 1.00 означає лише «розтин роблять тим, хто помер» — ознака є наслідком результату, а не предиктором; '
        'на момент госпіталізації її немає. Кореляція Пірсона з бінарною ціллю для дати ще й недопустима.',
        'Виключити Дату розтину (і Виписку) з ознак; для числових ознак × бінарна ціль — точковий бісеріальний '
        'коефіцієнт на очищених даних.'),
]

assert len(ВИПРАВЛЕННЯ) == 10, f'Знайдено {len(ВИПРАВЛЕННЯ)} помилок із 10'
for p in ВИПРАВЛЕННЯ:
    assert len(p) == 4 and all(str(x).strip() for x in p), 'Заповніть усі чотири поля'
    assert len(str(p[2])) >= 30 and len(str(p[3])) >= 25, 'Пояснення закороткі'

pd.DataFrame(ВИПРАВЛЕННЯ, columns=['Розділ', 'Що не так', 'Чому число неправильне', 'Як правильно'])
```

Out[20]:

	Розділ	Що не так	Чому число неправильне	Як правильно
0	1	Середнє обчислено для номінальної шкали (помер/жив); 1 і 2 — мітки, а не величини.	1.50 не означає «посередині між смертю й одужанням»: такого стану не існує. При кодуванні 0/1 вийшло б 0.50, при 1/0 — 0.50 у протилежному сенсі; число залежить лише від вибору кодів.	Мода й частоти: помер 61 (50.4 %), вижив 60 (49.6 %) — летальність 50.4 %.
1	2	Дані непридатні: одна номінальна категорія записана чотирма написаннями (ж/жін, ч/чол).	nunique = 4 рахує варіанти написання, а не статі; «4 статі» та «найбільша група ж (46 %)» — артефакт введення, реальна частка жінок інша.	Нормалізувати написання (перша літера після strip) і рахувати частоти: ж 75 (62 %), ч 46 (38 %).
2	3	Порядкова шкала: порядок узято алфавітний, написання не уніфіковано, а потім пораховано середнє кодів.	Алфавіт ставить «важкий» найлегшим, а «середній» найважчим; 12 «рівнів» замість 5; середнє 5.9 кодів без відстаней — порядкова шкала середнього не допускає, тому «середній ступінь — легкий» хибне.	Уніфікувати написання, задати порядок вручну (легкий<середній<важкий<вкрай важкий<критичний) і рахувати медіану/моду: медіана — «середній» (n = 42).
3	4	Дані непридатні: to_numeric(errors=coerce) мовчки викинув 17 текстових записів — 16 діапазонів («70-80%», «до 17%») і рядок із пробілів.	39.6 % пораховано лише на 27 із 43 реально заповнених КТ; відкинуті діапазони здебільшого великі (60–80 %), тож середнє зміщене донизу, і це не «середній обсяг ураження» відділення.	Розібрати діапазони (середина інтервалу, «до 17%» → верхня межа), привести до однієї одиниці, вказати n; для асиметричних даних — медіана з IQR.
4	5	Дані непридатні: значення 0.9 — сатурація, записана часткою (90 %), а не 0.9 %.	Мінімум 0.9 фізіологічно неможливий, середнє 82.05 занижене через одну помилку; крім того, середнє не каже нічого про «більшість» пацієнтів.	Виправити 0.9 → 90 (або відкинути), повідомляти медіану 84 % з IQR (79.75–89.25 %) і частку spO2 < 90 %.
5	6	Інтервальна шкала: коефіцієнт варіації (std/mean) обчислено для дат, у яких нуль умовний (1970-01-01).	0.595 % — це розкид дат відносно відстані від 1970 року; перенісши нуль на 2021-01-01, отримаємо зовсім інше число. Однорідності потоку госпіталізацій воно не вимірює.	Відмовитися від CV; описати розкид у днях (std ≈ 113 днів, розмах), або CV інтервалів між поступленнями.
6	7	Номінальна × номінальна: Пірсон на кодах статі та смерті; висновок «близько нуля» хибний.	r = 0.177 — це ф для таблиці 2×2, а не «відсутність лінійного зв'язку»: лінійності для категорій не існує, і 0.177 — не нуль; значущість не перевірено.	Таблиця спряженості, χ^2 і коефіцієнт Крамера: $\chi^2 = 3.78$, $p \approx 0.052$, $V = 0.18$ — слабкий зв'язок на межі значущості.
7	8	Min-max застосовано до всіх числових стовпців, включно з номінальним помер/жив і майже порожнім/сталим ФЕРИТ2.	ФЕРИТ2 має одне значення: max − min = 0, тож замість [0, 1] отримано мовчазні NaN; «усі ознаки нормалізовано» — неправда, а нормалізована мітка помер/жив не є величиною.	Перед нормалізацією перевіряти розмах > 0, виключати сталі й ідентифікаційні/номінальні стовпці, номінальні кодувати one-hot.

	Розділ	Що не так	Чому число неправильне	Як правильно
8	9	Дані непридатні для dropna(): кожен рядок має пропуск хоча б в одному з 77 стовпців (ФЕРИТ2 — 120 NaN).	Залишилось 0 рядків із 121, а висновок стверджує «повністю заповнений набір, придатний для моделі» — насправді даних для моделі немає взагалі.	Видаляти пропуски лише в потрібних для аналізу стовпцях (dropna(subset=...)), відкинути стовпці з >50 % NaN, решту імпутувати.
9	10	Витік цільової змінної + інтервальна шкала: дата розтину існує лише для померлих, NaT стає числом $-9.2 \cdot 10^{18}$.	r = 1.00 означає лише «розтин роблять тим, хто помер» — ознака є наслідком результату, а не предиктором; на момент госпіталізації її немає. Кореляція Пірсона з бінарною ціллю для дати ще й недопустима.	Виключити Дату розтину (і Виписку) з ознак; для числових ознак × бінарна ціль — точковий бісеріальний коефіцієнт на очищених даних.

Виправте щонайменше три помилки в коді

Оберіть три з десяти та покажіть правильне обчислення поруч із неправильним.

In [21]:
```
# --- Розділ 1: середнє номінальної ознаки -> частоти
print('РОЗДІЛ 1')
print('  неправильно: середнє помер/жив =', round(df['помер/жив'].mean(),
2))
частки = df['помер/жив'].map({1: 'помер', 2: 'вижив'}).value_counts()
print('  правильно  :', частки.to_dict(),
      f'-> летальність {100 * частки["помер"] / частки.sum():.1f} %')
print()

# --- Розділ 3: алфавітний порядок + середнє кодів -> заданий порядок +
медіана
print('РОЗДІЛ 3')
сирі = df['ступінь КТ'].value_counts().sort_index()
коди_алф = {н: і for і, н in enumerate(сирі.index)}
сер = df['ступінь КТ'].map(коди_алф).mean()
print('  неправильно: «найлегший» =', сирі.index[0], '| середнє кодів =',
round(сер, 2),
      '->', сирі.index[int(round(сер))])
print('  правильно  : рівні за заданим порядком:',
list(кт.value_counts(sort=False).items()))
print('                медіана =',
ПОРЯДОК_КТ[int(кт.dropna().cat.codes.median())],
      '| мода =', кт.mode()[0], f'| n = {кт.notna().sum()}')
print()

# --- Розділ 6: CV дат залежить від вибору нуля -> розкид у днях
print('РОЗДІЛ 6')
дати = pd.to_datetime(df['Поступлення'], errors='coerce').dropna()
від_1970 = (дати - pd.Timestamp('1970-01-01')).dt.days
від_2021 = (дати - pd.Timestamp('2021-01-01')).dt.days
print(f'  неправильно: CV від 1970-01-01 = {100 * від_1970.std() /
від_1970.mean():.3f} %')
print(f'               CV від 2021-01-01 = {100 * від_2021.std() /
від_2021.mean():.1f} %   <- ті самі дати, інший «нуль»')
print(f'  правильно  : стд. відхилення = {від_1970.std():.0f} днів, '
      f'розмах {дати.min().date()} — {дати.max().date()} ({(дати.max() -
дати.min()).days} днів)')
print()
```

```
# --- Розділ 7: Пірсон стать × летальність -> χ² і Крамер
print('РОЗДІЛ 7')
стать = df['Стать'].astype(str).str.strip().str[0]
помер = (df['помер/жив'] == 1).astype(int)
print('  неправильно: Пірсон r =', round(стать.map({'ч': 0, 'ж':
1}).corr(помер), 3), '-> «зв’язку немає»')
таблиця = pd.crosstab(стать, df['помер/жив'].map({1: 'помер', 2:
'вижив'}))
χ2, p_χ2, dof, _ = stats.chi2_contingency(таблиця, correction=False)
V = np.sqrt(χ2 / (таблиця.values.sum() * (min(таблиця.shape) - 1)))
print('  правильно  :'); print(таблиця.to_string())
print(f'               χ² = {χ2:.2f}, p = {p_χ2:.3f}, V Крамера =
{V:.3f}')
print('               -> слабкий зв’язок на межі значущості (летальність
жінок 57 %, чоловіків 39 %)')
print('                  — висновок «зв’язку немає» не обґрунтований.')
```

```
РОЗДІЛ 1
  неправильно: середнє помер/жив = 1.5
  правильно  : {'помер': 61, 'вижив': 60} -> летальність 50.4 %

РОЗДІЛ 3
  неправильно: «найлегший» = важкий | середнє кодів = 5.9 -> легкий
  правильно  : рівні за заданим порядком: [('легкий', 7), ('середній',
18), ('важкий', 10), ('вкрай важкий', 4), ('критичний', 3)]
               медіана = середній | мода = середній | n = 42

РОЗДІЛ 6
  неправильно: CV від 1970-01-01 = 0.595 %
               CV від 2021-01-01 = 30.0 %   <- ті самі дати, інший «нуль»
  правильно  : стд. відхилення = 113 днів, розмах 2021-02-25 — 2022-06-03
(463 днів)

РОЗДІЛ 7
  неправильно: Пірсон r = 0.177 -> «зв’язку немає»
  правильно  :
помер/жив  вижив  помер
Стать
ж             32     43
ч             28     18
               χ² = 3.78, p = 0.052, V Крамера = 0.177
               -> слабкий зв’язок на межі значущості (летальність жінок 57
%, чоловіків 39 %)
                  — висновок «зв’язку немає» не обґрунтований.
```

Етап 7. Висновки та індивідуальне питання

In [22]:
```
ВИСНОВКИ = [
    'У стовпці «помер/жив» 61 летальний випадок і 60 виживань
(летальність 50.4 %); усі 61 смерть '
    'припадають на пацієнтів із «Перебіг» = «важкий» (летальність у групі
68 %), а серед «серед важ» '
    '(30 осіб) не помер ніхто; оскільки «помер/жив» номінальна, зв’язок
описую таблицею частот, а не середнім кодом.',
```

```
    'Ступінь КТ і клінічний «Перебіг» пов'язані монотонно: ρ Спірмена =
0.63 (p < 0.001, n = 42); '
    'при цьому Пірсон на тих самих даних дає від 0.42 до 0.60 залежно від
довільного кодування рівнів, '
    'що й доводить його непридатність для порядкових шкал.',

    'Лабораторні стовпці мого варіанта мають дефекти, які describe() не
показує: «Креат1» і «Гемогл2» '
    'зберігаються як object через рядки «даних», «немає», «109.9»;
«БРзаг2» приймає лише 21 значення, '
    'і 89 % записів — кратні 1.7 (11.9, 13.6, 15.3, 17.0, 18.7), тобто
значення перераховані з мг/дл із грубим кроком.',

    'У «spO2 без дот» одне значення 0.9 записане часткою замість 90 %:
після виправлення середнє зростає '
    'з 82.05 до 82.79, а std падає з 12.2 до 9.7; медіана (84 %) стійка
до цієї помилки. Медіанна '
    'сатурація померлих — 80 %, тих, хто вижив, — 89 %.',

    'У «Виписка» дві дати неіснуючі («24.024.2021», «20.24.2021»), у двох
записах виписка раніша за '
    'поступлення (до −29 днів), а в одному перебування триває 194 дні —
інтервальна шкала дозволяє рахувати тривалості, але лише після перевірки,
що вони невід'ємні.',
]
assert len(ВИСНОВКИ) >= 3 and all(len(в) >= 60 for в in ВИСНОВКИ), \
    'Потрібні три змістовні висновки'
for i, в in enumerate(ВИСНОВКИ, 1):
    print(f'{i}. {в}')
```

1. У стовпці «помер/жив» 61 летальний випадок і 60 виживань (летальність 50.4 %); усі 61 смерть припадають на пацієнтів із «Перебіг» = «важкий» (летальність у групі 68 %), а серед «серед важ» (30 осіб) не помер ніхто; оскільки «помер/жив» номінальна, зв'язок описую таблицею частот, а не середнім кодом.
2. Ступінь КТ і клінічний «Перебіг» пов'язані монотонно: ρ Спірмена = 0.63 (p < 0.001, n = 42); при цьому Пірсон на тих самих даних дає від 0.42 до 0.60 залежно від довільного кодування рівнів, що й доводить його непридатність для порядкових шкал.
3. Лабораторні стовпці мого варіанта мають дефекти, які describe() не показує: «Креат1» і «Гемогл2» зберігаються як object через рядки «даних», «немає», «109.9»; «БРзаг2» приймає лише 21 значення, і 89 % записів — кратні 1.7 (11.9, 13.6, 15.3, 17.0, 18.7), тобто значення перераховані з мг/дл із грубим кроком.
4. У «spO2 без дот» одне значення 0.9 записане часткою замість 90 %: після виправлення середнє зростає з 82.05 до 82.79, а std падає з 12.2 до 9.7; медіана (84 %) стійка до цієї помилки. Медіанна сатурація померлих — 80 %, тих, хто вижив, — 89 %.
5. У «Виписка» дві дати неіснуючі («24.024.2021», «20.24.2021»), у двох записах виписка раніша за поступлення (до −29 днів), а в одному перебування триває 194 дні — інтервальна шкала дозволяє рахувати тривалості, але лише після перевірки, що вони невід'ємні.

In [23]:
```
print('ВАШЕ ПИТАННЯ:'); print(В['питання']); print()

пж = df['помер/жив']
print(f'mean = {пж.mean():.3f}   std = {пж.std():.3f}   median =
{пж.median():.0f}   '
      f'25% = {пж.quantile(.25):.0f}   75% = {пж.quantile(.75):.0f}')
інше = пж.map({1: 2, 2: 1})        # ті самі пацієнти, лише мітки
```

```
поміняно місцями
print(f'після обміну міток 1<->2: mean = {інше.mean():.3f}   median =
{інше.median():.0f}   '
      f'std = {інше.std():.3f}')
print()

ВІДПОВІДЬ = '''
«помер/жив» — номінальна бінарна ознака: 1 і 2 лише назви категорій. Тип
int64 змушує pandas
вважати стовпець числовим, тож describe() без жодного попередження видає,
зокрема, три числа:

1) Середнє = 1.496. Його «прочитали» б як «пацієнт наполовину помер».
Насправді це лише
   1 + частка міток «2»: при кодуванні 0/1 вийшло б 0.496, при 10/20 —
14.96. Число
   визначає вибір кодів, а не результат лікування. Змістовна статистика —
частоти й мода:
   61 помер (50.4 %), 60 вижили.

2) Стандартне відхилення = 0.502. Воно вимірює розкид відстаней від
«середнього», але
   відстані між «помер» і «вижив» не існує; при кодуванні 1/10 std стала
б у 9 разів
   більшою за тих самих пацієнтів. Для номінальної шкали міра розкиду —
частоти (або
   ентропія), не std.

3) Медіана = 1 (та квартилі 25 % = 1, 75 % = 2). Медіана вимагає порядку,
а «смерть менша
   за життя» — не властивість даних, а випадок кодування. Якщо поміняти
мітки місцями,
   медіана стане 2 — «медіанний пацієнт вижив», хоча жоден пацієнт не
змінився. Крім того,
   при 61/60 вона залежить від одного пацієнта.

pandas не скаржиться, бо бачить лише dtype: шкали вимірювання він не
знає. Правильно — або
перетворити стовпець на category, тоді describe() видасть
count/unique/top/freq, або
відразу перекодувати в індикатор «помер» (0/1), де середнє вже має зміст:
це частка
померлих, 0.504.
'''
assert len(ВІДПОВІДЬ.strip()) >= 200, 'Відповідь має бути розгорнутою
(від 200 символів)'
print(ВІДПОВІДЬ)
```

ВАШЕ ПИТАННЯ:
Стовпець «помер/жив» містить числа 1 і 2. Які три різні статистики pandas порахує для нього без жодної скарги — і чому кожна з них безглузда?

mean = 1.496   std = 0.502   median = 1   25% = 1   75% = 2
після обміну міток 1<->2: mean = 1.504   median = 2   std = 0.502

«помер/жив» — номінальна бінарна ознака: 1 і 2 лише назви категорій. Тип int64 змушує pandas
вважати стовпець числовим, тож describe() без жодного попередження видає, зокрема, три числа:

1) Середнє = 1.496. Його «прочитали» б як «пацієнт наполовину помер». Насправді це лише
   1 + частка міток «2»: при кодуванні 0/1 вийшло б 0.496, при 10/20 — 14.96. Число
   визначає вибір кодів, а не результат лікування. Змістовна статистика — частоти й мода:
   61 помер (50.4 %), 60 вижили.

2) Стандартне відхилення = 0.502. Воно вимірює розкид відстаней від «середнього», але
   відстані між «помер» і «вижив» не існує; при кодуванні 1/10 std стала б у 9 разів
   більшою за тих самих пацієнтів. Для номінальної шкали міра розкиду — частоти (або
   ентропія), не std.

3) Медіана = 1 (та квартилі 25 % = 1, 75 % = 2). Медіана вимагає порядку, а «смерть менша
   за життя» — не властивість даних, а випадок кодування. Якщо поміняти мітки місцями,
   медіана стане 2 — «медіанний пацієнт вижив», хоча жоден пацієнт не змінився. Крім того,
   при 61/60 вона залежить від одного пацієнта.

pandas не скаржиться, бо бачить лише dtype: шкали вимірювання він не знає. Правильно — або
перетворити стовпець на category, тоді describe() видасть count/unique/top/freq, або
відразу перекодувати в індикатор «помер» (0/1), де середнє вже має зміст: це частка
померлих, 0.504.

Етап 8. Декларація про використання інструментів ШІ

Користуватися мовними моделями дозволено. Це нормальна інженерна практика.

Обов'язковою є прозорість: ви вказуєте, де саме і як скористалися інструментом — так само, як у науковій статті вказують використане програмне

забезпечення. Задекларована допомога порушенням не є.

Порушенням є інше: здати роботу, яку ви не можете пояснити. На захисті вас попросять показати конкретний рядок свого коду, пояснити, чому він саме такий, і внести в нього невелику зміну на місці.

Для кожного етапу оберіть одне з формулювань:

- `'ні'` — інструментами ШІ не користувався
- `'синтаксис'` — питав про назву функції або синтаксис, код писав сам
- `'код, перевірено'` — код згенеровано, я його прочитав, перевірив і розумію
- `'текст, перероблено'` — згенеровано чернетку тексту, яку я переписав по суті
- `'текст, як є'` — згенерований текст залишено майже без змін

In [24]:
```
ДЕКЛАРАЦІЯ = {
    'етап 1 — паспорт змінних':        'текст, як є',
    'етап 2 — допустимі статистики':   'код, перевірено',
    'етап 3 — безглузді числа':        'текст, як є',
    'етап 4 — міра зв'язку':           'код, перевірено',
    'етап 5 — підготовка до моделі':   'код, перевірено',
    'етап 6 — виправлення аналізу':    'текст, як є',
    'етап 7 — висновки й відповідь':   'текст, як є',
}

ЩО_САМЕ_Я_ПЕРЕВІРИВ = (
    'Перезапустила ноутбук на чистому ядрі (Restart & Run All).
Перевірила вручну: сирі значення '
    'стовпців (рядки «даних», «немає», дату «24.024.2021», spO2 = 0.9);
що порядок Перебігу й ступеня КТ '
    'задано вручну, а не за алфавітом; що Спірмен не змінюється при зміні
кодів, а Пірсон змінюється; '
    'що нормалізація сталого ФЕРИТ2 дає помилку, а не NaN; числа в
розділах 1, 3, 6, 7 помилкового звіту.'
)
ПІДТВЕРДЖУЮ = True      # я можу пояснити кожен рядок свого коду
                        # і внести в нього зміни на вимогу під час
захисту
```

In [25]:
```
# --- ФІНАЛЬНА САМОПЕРЕВІРКА ---
ФОРМУЛЮВАННЯ = {'ні', 'синтаксис', 'код, перевірено', 'текст,
перероблено', 'текст, як є'}

перевірки = {
    'заповнено титульні поля':        bool(ПРІЗВИЩЕ_ІМЯ and ГРУПА and
НОМЕР),
    'етап 1: паспорт із 8 стовпців':  all(ПАСПОРТ[c][0] and ПАСПОРТ[c][1]
for c in МОЇ),
    'етап 3: три безглузді числа':    len(БЕЗГЛУЗДІ) >= 3,
    'етап 4: міру обрано й пояснено': bool(ОБРАНА_МІРА and
len(ЧОМУ_САМЕ_ВОНА) >= 40),
    'етап 5: підготовку описано':     all(len(ПІДГОТОВКА[c].strip()) >=
15 for c in МОЇ),
    'етап 6: знайдено 10 помилок':    len(ВИПРАВЛЕННЯ) == 10,
    'етап 7: три висновки':           len(ВИСНОВКИ) >= 3,
```

```
    'етап 7: відповідь на питання':   len(ВІДПОВІДЬ.strip()) >= 200,
    'декларацію заповнено':           all(v in ФОРМУЛЮВАННЯ for v in
ДЕКЛАРАЦІЯ.values()),
    'опис перевірки ≥ 120 символів':  len(ЩО_САМЕ_Я_ПЕРЕВІРИВ.strip()) >=
120,
    'підтвердження авторства':        ПІДТВЕРДЖУЮ is True,
}

print('ЧЕК-ЛИСТ ГОТОВНОСТІ')
print('=' * 52)
for назва, ок in перевірки.items():
    print(('  ГОТОВО     ' if ок else '  НЕ ГОТОВО ') + назва)
print('=' * 52)

assert all(перевірки.values()), 'Робота не готова до здачі — див. чек-
лист вище'
print()
print(f'Робота варіанта {В["варіант"]} готова до захисту.')
print(f'{ПРІЗВИЩЕ_ІМЯ}, {ГРУПА}')
```

```
ЧЕК-ЛИСТ ГОТОВНОСТІ
====================================================
  ГОТОВО     заповнено титульні поля
  ГОТОВО     етап 1: паспорт із 8 стовпців
  ГОТОВО     етап 3: три безглузді числа
  ГОТОВО     етап 4: міру обрано й пояснено
  ГОТОВО     етап 5: підготовку описано
  ГОТОВО     етап 6: знайдено 10 помилок
  ГОТОВО     етап 7: три висновки
  ГОТОВО     етап 7: відповідь на питання
  ГОТОВО     декларацію заповнено
  ГОТОВО     опис перевірки ≥ 120 символів
  ГОТОВО     підтвердження авторства
====================================================

Робота варіанта 3 готова до захисту.
Бобринок Ангеліна, ШІ-32
```

Перед здачею

Виконайте **Kernel → Restart & Run All**. Ноутбук має пройти згори донизу без жодної помилки — це перше, що перевіряється на захисті.